

(1)简述下你是如何完成第一次挑战的。

这次挑战我用了 Deepseek/豆包/千问作为完成任务的辅助工具。在这个过程中我遇到了各种问题，尝试了各种解决方案。在环境配置过程中，我尝试在本地 WSL 环境中安装 SGLang 0.5.14，但是因为我的显卡（RTX 5060，SM120 架构）和 CUDA 13.1 版本过新，官方预编译包不兼容，于是我在 AI 的建议下尝试从 GitHub 拉取源码手动编译 sgl-kernel，但是因为网络限制和架构不匹配，一直在报错。然后我又转向尝试 Docker 方案，配置了国内镜像加速器，尝试拉取适配 SM120 的社区镜像，但是由于网络不稳定，换多条路径多次下载都没成功，所以最后环境配置没有完成，SGLang 没能启动。我通过云端 API 替代本地推理，并用 Python 脚本模拟了 Mooncake trace 的 Poisson 到达过程，完成了请求流程的验证。

(2)你觉得哪部分工作最困难，你是如何克服这个困难的。

我觉得最困难的部分是环境配置部分，我遇到的困难是本地硬件与推理框架的不兼容。RTX 5060 是刚发布不久的新架构，SGLang 0.5.14 的预编译内核无法正常加载，导致 libnvrtc.so.13 缺失和 sgl_kernel 编译失败，而且 GitHub 克隆和 Docker Hub 拉取镜像也频频报错。我通过询问 AI 排查错误日志、配置 Docker 国内镜像源，并试多种镜像仓库来尝试克服但是最终还是没有在本地启动服务，但我学会了如何从报错中定位问题以及了解了在实践中可能出现的问题。

(3)你觉得类似的从 0 到 1 的科研工作，需要包含哪些方面的研究，对你今后的科研工作有什么启发。

通过这次任务，我发现从 0 到 1 的科研工作绝不仅仅是研究算法，它包含了问题定义、文献调研、底层系统适配、实验设计评估、以及大量报错后的排错迭代。我深刻体会到理论与实践的差别，在实践中可能会遇到各种各样意想不到的问题需要我们冷静思考解决办法并且耐心应对。我希望我能够在扎实理论基础的同时，也要提升应对困难的耐心和能力，做到学以致用。