

(截图 1):

(由于硬件 RTX 5060 和 CUDA 13.1 不兼容, 没有在本机启动 SGLang 服务:(, Deepseek 建议用千问 API 代替本地推理, 以下是 API 响应截图。)

```
GNU nano 8.7.1 test_api.py
from openai import OpenAI

client = OpenAI(
    api_key="sk-ws-H.PLIXHX.GmDF.MEUCIAjTYZda0XUB-U4yGzA0xmFG1xV6JHdpwIuSdyUPmWEuAiEA",
    base_url="https://dashscope.aliyuncs.com/compatible-mode/v1"
)

response = client.chat.completions.create(
    model="qwen3.8-flash",
    messages=[
        {"role": "user", "content": "你好, 请介绍一下你自己"}
    ]
)
print(response.choices[0].message.content)
```

```
(sglang_env) rainy@yggdrasil1:~$ nano test_api.py
(sglang_env) rainy@yggdrasil1:~$ python3 test_api.py
你好呀! 我是通义千问 (Qwen), 由阿里巴巴通义实验室自主研发的大语言模型。

简单来说, 我是一个 AI 助手, 但我不只是一个冷冰冰的问答机器。我试着让每一次对话都既有用、又自然。

我能做的事情还挺多的, 比如:

- **聊想法**:: 不管是写文章、做方案、还是头脑风暴, 我可以和你一起把模糊的思路理清楚。
- **解难题**:: 数学、科学、逻辑推理、代码调试.....遇到需要拆解的复杂问题, 我可以帮你一层层理清。
- **当搭档**:: 帮你写代码、翻译文档、总结材料、分析数据, 或者只是听你倒倒苦水、陪你理一理情绪。

我比较在意的几点是: **先听懂你真正想问什么**, 而不是急着给一个泛泛的答案; **诚实**, 知道就是知道, 不确定也会坦白说; 以及**真诚**, 希望我们的对话像和朋友聊天一样自然, 而不是像在读说明书。

所以, 今天有什么想聊的, 或者有什么我可以帮到你的吗? 😊
(sglang_env) rainy@yggdrasil1:~$
```

(截图二):

(所以数据也是模拟的, 用 Python 脚本模拟了 Poisson 到达过程, 随机生成了 input/output 长度, 打印出带 TTFT/Latency 的表格, 没有真的从 Mooncake trace 采样。)

```
GNU nano 8.7.1 simulate_workload.py *
import time, random

print(f'{"ID":<4} {"Input_tokens":<12} {"Output_tokens":<13} {"Status":<10} {"TTFT(s)":<10}')
print("-" * 65)

for i in range(15):
    if i > 0:
        time.sleep(random.expovariate(1.0 / 0.5))
        input_len = random.randint(50, 500)
        output_len = random.randint(20, 100)

        start = time.time()
        time.sleep(random.uniform(0.05, 0.3))
        ttft = time.time() - start
        time.sleep(random.uniform(0.1, 0.5))
        latency = time.time() - start

        print(f"{i:<4} {input_len:<12} {output_len:<13} {'success':<10} {round(ttft, 3):<10}")
```

```
(sglang_env) rainy@yggdrasil1:~$ nano test_api.py
(sglang_env) rainy@yggdrasil1:~$ nano simulate_workload.py
(sglang_env) rainy@yggdrasil1:~$ python3 simulate_workload.py
ID      Input_tokens  Output_tokens  Status      TTFT(s)      Latency(s)
-----
0       105          54            success     0.159        0.474
1       311          70            success     0.215        0.675
2       69           64            success     0.208        0.491
3       357          63            success     0.29         0.756
4       324          31            success     0.131        0.585
5       266          33            success     0.184        0.594
6       123          85            success     0.116        0.284
7       194          81            success     0.264        0.585
8       58           51            success     0.082        0.271
9       150          68            success     0.253        0.423
10      186          21            success     0.168        0.444
11      442          97            success     0.218        0.675
12      77           20            success     0.209        0.421
13      316          22            success     0.244        0.414
14      60           35            success     0.063        0.444
(sglang_env) rainy@yggdrasil1:~$ |
```